

ADVANCED STATISTICAL REASONING

Laura Apicella

1. HOME — Regressione Lineare Multipla

Il dataset analizzato contiene informazioni relative a 100 appartamenti. Per ciascuna unità immobiliare sono disponibili le seguenti variabili: un codice identificativo (*id*), le tasse annuali in dollari (*Taxes*), il numero di camere da letto (*Bedrooms*) e di bagni (*Baths*), il quadrante della città in cui è situato l'immobile (*Quadrant*), una variabile dummy che indica l'appartenenza al quadrante nord-ovest (*NW*, 1 = NW, 0 = altro), la superficie abitativa (*Size*) e la dimensione del lotto (*Lot*). La variabile target è il prezzo di vendita in dollari (*Price*).

Prima di procedere con la costruzione del modello, è stata condotta un'analisi esplorativa delle correlazioni tra le variabili tramite la correlazione di Pearson:

Pearson Correlation Coefficients, N = 100 Prob > r under H0: Rho=0							
	price	Taxes	Bedrooms	Baths	NW	size	lot
price	1.00000	0.82376 <.0001	0.36338 0.0002	0.57116 <.0001	0.20450 0.0413	0.76126 <.0001	0.71377 <.0001
Taxes	0.82376 <.0001	1.00000	0.39880 <.0001	0.55050 <.0001	0.14914 0.1386	0.73791 <.0001	0.73554 <.0001
Bedrooms	0.36338 0.0002	0.39880 <.0001	1.00000	0.45778 <.0001	-0.11447 0.2568	0.57329 <.0001	0.21204 0.0342
Baths	0.57116 <.0001	0.55050 <.0001	0.45778 <.0001	1.00000	0.07882 0.4357	0.64085 <.0001	0.33328 0.0007
NW	0.20450 0.0413	0.14914 0.1386	-0.11447 0.2568	0.07882 0.4357	1.00000	-0.04093 0.6860	0.22906 0.0219
size	0.76126 <.0001	0.73791 <.0001	0.57329 <.0001	0.64085 <.0001	-0.04093 0.6860	1.00000	0.53449 <.0001
lot	0.71377 <.0001	0.73554 <.0001	0.21204 0.0342	0.33328 0.0007	0.22906 0.0219	0.53449 <.0001	1.00000

Tabella 1 — Matrici di correlazione di Pearson tra prezzo di vendita e variabili esplicative

I risultati evidenziano che il prezzo di vendita è fortemente correlato con le variabili *Taxes* ($r = 0.824$), *Size* ($r = 0.761$) e *Lot* ($r = 0.714$), suggerendo la possibile presenza di multicollinearità nel modello. Una correlazione positiva moderata si osserva per il numero di bagni ($r = 0.571$), mentre il numero di camere presenta un'associazione più contenuta ($r = 0.363$). La variabile *NW*, indicatore del quadrante abitativo, mostra una correlazione debole con il prezzo ($r = 0.205$). Tutte le correlazioni risultano comunque statisticamente significative ($p < 0.05$).

Sulla base di questa prima analisi, si ipotizza che *Size* e *Taxes* costituiranno i predittori più rilevanti, mentre *Bedrooms* potrebbe risultare non significativo una volta inclusa *Size*, data l'elevata correlazione tra le due variabili.

Si procede quindi con la stima di un modello di regressione lineare multipla completo, includendo tutti i potenziali predittori.

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	6	2.437365E11	40622747714	53.44	<.0001
Error	93	70696033318	760172401		
Corrected Total	99	3.144325E11			

Root MSE	27571	R-Square	0.7752
Dependent Mean	126698	Adj R-Sq	0.7607
Coeff Var	21.76137		

Parameter Estimates					
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	1	-3132.57675	16385	-0.19	0.8488
Taxes	1	19.71777	5.20056	3.79	0.0003
Bedrooms	1	-5441.10996	5261.85090	-1.03	0.3038
Baths	1	9814.04821	7286.94023	1.35	0.1813
NW	1	13295	6809.29215	1.95	0.0539
size	1	37.17734	8.95291	4.15	<.0001
lot	1	1.43908	0.49597	2.90	0.0046

Tabella 2 — Risultati della regressione lineare multipla: modello completo

Il modello risulta globalmente significativo ($F = 53.44$, $p < 0.0001$), con un R^2 pari a 0.7752, indicando che il 77.52% della variabilità del prezzo di vendita è spiegata dalle variabili incluse. L' R^2 aggiustato (0.7607) conferma l'assenza di overfitting.

Dall'analisi delle stime dei parametri emerge tuttavia che *Intercetta*, *Bedrooms* e *Baths* non risultano statisticamente significativi. Si procede pertanto con una procedura di eliminazione manuale delle variabili (manual stepwise backward), rimuovendo dapprima la variabile meno significativa, *Bedrooms*.

Root MSE	27581	R-Square	0.7726
Dependent Mean	126698	Adj R-Sq	0.7605
Coeff Var	21.76939		

Parameter Estimates					
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	1	-13639	12859	-1.06	0.2916
Taxes	1	19.56333	5.20033	3.76	0.0003
Baths	1	8693.69664	7208.60126	1.21	0.2308
NW	1	14000	6777.57771	2.07	0.0416
size	1	33.96549	8.39995	4.04	0.0001
lot	1	1.48986	0.49371	3.02	0.0033

Tabella 3 — Risultati della regressione lineare dopo la rimozione della variabile Bedrooms

Il modello intermedio ottenuto presenta un R^2 pressoché invariato (0.7726), tuttavia *Baths* rimane non significativo ($p = 0.23$) e viene anch'esso rimosso nella fase successiva.

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	4	2.418172E11	60454292098	79.09	<.0001
Error	95	72615351207	764372118		
Corrected Total	99	3.144325E11			

Root MSE	27647	R-Square	0.7691
Dependent Mean	126698	Adj R-Sq	0.7593
Coeff Var	21.82140		

Parameter Estimates					
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	1	-4853.78768	10622	-0.46	0.6488
Taxes	1	20.71576	5.12399	4.04	0.0001
NW	1	15050	6737.46099	2.23	0.0278
size	1	38.35445	7.58877	5.05	<.0001
lot	1	1.39906	0.48911	2.86	0.0052

Tabella 4 — Risultati del modello finale di regressione lineare multipla

Il modello finale, composto da quattro predittori (*Taxes*, *NW*, *Size*, *Lot*), risulta pulito e robusto. Tutti i parametri stimati sono statisticamente significativi, con un R^2 pari a 0.7691 e un R^2 aggiustato di 0.7593. La perdita di potere esplicativo rispetto al modello completo è minima, a fronte di una sostanziale riduzione della complessità del modello.

La non significatività dell'intercetta risulta coerente con il contesto applicativo del modello. Infatti, l'intercetta rappresenta il prezzo di vendita stimato nel caso in cui tutte le variabili esplicative assumano valore pari a zero, situazione che non risulta realistica nel mercato immobiliare, poiché non esistono appartamenti con dimensione, numero di stanze o altre caratteristiche pari a zero.

In sintesi, a parità di tutte le altre condizioni, il prezzo di vendita aumenta di **\$38.35** per ogni piede quadrato aggiuntivo di superficie abitativa (predittore più rilevante), di **\$20.72** per ogni dollaro aggiuntivo di tasse, di **\$1.40** per ogni piede quadrato di lotto in più. Infine, la localizzazione nel quadrante North-West comporta un incremento stimato del prezzo pari a **\$15.050**.

2. Titanic — Regressione Logistica

L'obiettivo dell'analisi è costruire un modello statistico capace di spiegare la sopravvivenza dei passeggeri del Titanic in funzione delle loro caratteristiche individuali.

Il dataset contiene informazioni relative a 2201 persone imbarcate, includendo classe di viaggio (*Class*), sesso (*Sex*), fascia d'età (*Age*) e stato di sopravvivenza (*Survived*), oltre alla frequenza delle osservazioni (*Freq*).

Poiché la variabile risposta è dicotomica (sopravvissuto/non sopravvissuto), l'analisi è stata condotta mediante regressione logistica.

Il risultato ottenuto è il seguente:

Response Profile		
Ordered Value	Survived	Total Frequency
1	No	1490
2	Yes	711

Probability modeled is Survived='Yes'.

Tabella 1 - Distribuzione dei passeggeri per stato di sopravvivenza (*Survived*)

Class Level Information				
Class	Value	Design Variables		
Class	1st	1	0	0
	2nd	0	1	0
	3rd	0	0	1
	Crew	0	0	0
Sex	Female	1		
	Male	0		
Age	Adult	1		
	Child	0		

Model Convergence Status	
Convergence criterion (GCONV=1E-8) satisfied.	

Tabella 2 - Codifica delle variabili categoriche e costruzione delle dummy variables

Dal profilo della risposta emerge uno sbilanciamento nel campione: 1490 passeggeri non sono sopravvissuti, contro 711 sopravvissuti. La parametrizzazione di riferimento (*param=ref*) adottata da SAS definisce come categoria baseline un maschio bambino appartenente alla Crew, rispetto al quale vanno interpretati tutti i coefficienti e gli Odds Ratio. Il criterio di convergenza risulta soddisfatto, confermando la corretta stima del modello.

Successivamente, l'output prodotto evidenzia:

Model Fit Statistics		
Criterion	Intercept Only	Intercept and Covariates
AIC	2771.457	2222.061
SC	2777.153	2256.241
-2 Log L	2769.457	2210.061

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	559.3956	5	<.0001
Score	556.7267	5	<.0001
Wald	402.3282	5	<.0001

Type 3 Analysis of Effects			
Effect	DF	Wald Chi-Square	Pr > ChiSq
Class	3	108.2432	<.0001
Sex	1	297.0678	<.0001
Age	1	18.9236	<.0001

Analysis of Maximum Likelihood Estimates						
Parameter		DF	Estimate	Standard Error	Wald Chi-Square	Pr > ChiSq
Intercept		1	-0.1724	0.2567	0.4508	0.5020
Class	1st	1	0.8577	0.1573	29.7149	<.0001
Class	2nd	1	-0.1604	0.1738	0.8521	0.3560
Class	3rd	1	-0.9201	0.1486	38.3441	<.0001
Sex	Female	1	2.4201	0.1404	297.0678	<.0001
Age	Adult	1	-1.0615	0.2440	18.9236	<.0001

Tabella 7 - Test globali di significatività del modello logistico (Likelihood Ratio, Score, Wald)

Odds Ratio Estimates			
Effect	Point Estimate	95% Wald Confidence Limits	
Class 1st vs Crew	2.358	1.732	3.209
Class 2nd vs Crew	0.852	0.606	1.197
Class 3rd vs Crew	0.398	0.298	0.533
Sex Female vs Male	11.247	8.541	14.809
Age Adult vs Child	0.346	0.214	0.558

Tabella 8 - Stime dei parametri e Odds Ratio del modello logistico

La prima tabella mostra il confronto tra il modello con sole intercette e il modello completo, evidenziando una forte riduzione dell'AIC, ad indicare un significativo miglioramento della capacità esplicativa del modello logistico.

I tre test globali (Likelihood Ratio, Score e Wald) risultano tutti altamente significativi ($p < .0001$), confermando che il modello con i predittori è sostanzialmente superiore al modello nullo.

Tutte e tre le variabili incluse nel modello risultano statisticamente significative, con un p -value $< .0001$. L'unica classe che non si differenzia statisticamente dalla Crew in termini di probabilità di sopravvivenza è la seconda classe.

Dall'analisi delle stime di massima verosimiglianza e dei relativi Odds Ratio emergono i seguenti risultati, tutti interpretati rispetto alla categoria di riferimento (Crew, Male, Child):

Sesso: il sesso rappresenta il fattore maggiormente influente: le donne mostrano odds di sopravvivenza circa 11 volte superiori rispetto agli uomini (11.247).

Classe di viaggio: i passeggeri di prima classe presentano probabilità di sopravvivenza significativamente più elevate rispetto all'equipaggio (2.358), mentre quelli di terza classe evidenziano probabilità inferiori (0.398).

Età: gli adulti mostrano odds di sopravvivenza inferiori rispetto ai bambini (0.346).

In sintesi, il modello evidenzia chiaramente il principio "**donne e bambini prima**": il sesso femminile e la giovane età risultano i fattori più protettivi, mentre viaggiare in terza classe rappresentava uno svantaggio significativo rispetto a tutte le altre categorie.

3. DOC.SAS — Analisi Fattoriale Esplorativa

Il dataset contiene le risposte di un campione di pazienti a 13 domande (scala 1–10) riguardanti l'opinione sul proprio medico curante. Le variabili con formulazione negativa sono state preventivamente invertite (moltiplicate per -1) per garantire una direzione omogenea delle risposte. L'obiettivo è esplorare la struttura di correlazione tra le variabili e individuare eventuali fattori latenti tramite analisi fattoriale esplorativa con metodo Maximum Likelihood:




Tabella 9 -Stime di Comunalità Preliminari e Autovalori




Figura 1 -Scree plot per l'individuazione del numero ottimale di fattori

Applicando il criterio di Kaiser (eigenvalue > 1), solo i primi 2 fattori superano la soglia. Lo scree plot mostra un chiaro gomito dopo il secondo fattore, con gli eigenvalori successivi che si appiattiscono verso zero — supportando l'estrazione di 2 fattori.

Si procede quindi implementando il modello a 2 fattori:

Rotated Factor Pattern		
	Factor1	Factor2
Q1	0.69078	0.12427
Q2	0.76069	0.08558
Q3	0.72827	0.07688
Q4	0.74429	0.11551
Q5	0.78177	0.03027
Q6	0.71728	0.11057
Q7	0.85395	0.06501
Q8	0.08687	0.69768
Q9	0.10123	0.71863
Q10	0.13941	0.72126
Q11	0.07314	0.77658
Q12	0.10391	0.75860
Q13	0.01355	0.81409

Significance Tests Based on 80 Observations			
Test	DF	Chi-Square	Pr > ChiSq
H0: No common factors	78	561.2154	<.0001
HA: At least one common factor			
H0: 2 Factors are sufficient	53	66.0603	0.1074
HA: More factors are needed			

Variance Explained by Each Factor		
Factor	Weighted	Unweighted
Factor1	10.2797934	4.04861684
Factor2	8.2165162	3.42408684

Tabella 10 - Pattern Fattoriale Ruotato e Varianza Spiegata da Ciascun Fattore

Tabella 11 - Test di Significatività dell'Analisi Fattoriale con 2 fattori

I test di significatività confermano che il modello fattoriale è appropriato: l'ipotesi nulla "nessun fattore comune" viene rifiutata con forza. Crucialmente, il test per la sufficienza di 2 fattori non viene rifiutato, indicando che 2 fattori sono statisticamente sufficienti a rappresentare la struttura di correlazione dei dati.

Dopo rotazione Varimax, emerge una struttura semplice e interpretabile. Il **Fattore 1** presenta saturazioni elevate da Q1 a Q7, mentre il **Fattore 2** satura principalmente da Q8 a Q13. Inoltre, il Fattore 1 spiega 4.05 unità di varianza (unweighted), il Fattore 2 ne spiega 3.42, per un totale di circa 7.47 su 13 variabili.

La struttura ottenuta suggerisce l'esistenza di due dimensioni latenti distinte nella percezione del medico curante. Il **Fattore 1** raggruppa le variabili Q1–Q7 e potrebbe essere interpretato come una dimensione relativa alla relazione e comunicazione col medico (competenza percepita, chiarezza, empatia). Il **Fattore 2** raggruppa Q8–Q13 e potrebbe riflettere aspetti legati all'organizzazione e accessibilità del servizio (tempi, disponibilità, struttura).

Tuttavia, SAS suggeriva in prima analisi di trattenere 3 fattori, scenario che può esser ulteriormente indagato:

ERROR: Commuality greater than 1.0.			
Significance Tests Based on 80 Observations			
Test	DF	Chi-Square	Pr > ChiSq
H0: No common factors	78	561.2154	<.0001
HA: At least one common factor			

Tabella 12 — Test di Significatività dell'Analisi Fattoriale con 3 fattori

La soluzione a 3 fattori non converge correttamente: SAS restituisce l'errore "**Commuality greater than 1.0**", restituendo dunque una soluzione impropria in cui la stima della comunaltà supera 1, il che è matematicamente impossibile per una proporzione di varianza spiegata.